



基于改进的神经网络和混沌时间序列 预测控制高炉炼铁过程




参赛队伍：A1053




重庆大学
CHONGQING UNIVERSITY

参赛团队：张阳阳、王懿泽、李琅

指导老师：重庆大学 肖剑



CONTENTS



- 1/ 问题重述
- 2/ 模型假设
- 3/ 符号说明
- 4/ 问题分析
- 5/ 数据预处理
- 6/ 问题一模型的建立与求解
- 7/ 问题二模型的建立与求解
- 8/ 问题三模型的建立与求解
- 9/ 问题四的心得体会
- 10/ 结论

- 11/ 模型的优缺点
- 12/ 参考文献
- 13/ 附录



一. 问题重述

“中国制造2025”是我国制造业升级的国家大战略。其技术核心是智能制造，智能化程度相当于“德国工业4.0”水平。通过大数据挖掘，确定生产过程的最佳途径与最佳参数控制范围，预测性地动态调整生产过程控制，获得最佳生产效果。本课题数学建模需要解决的问题如下：

- 从给定数据表中[Si]-[S]-FL-PML依序号排列的1000炉生产大数据中，自主选取学习样本和算法，建立[Si]预测动态数学模型，包括一步预测模型和二步预测模型。全面论述你的数学建模思路。
- 自主选取验证样本，验证你所建立的数学模型的预测成功率。包括数值预测成功率和炉温升降方向预测成功率，并讨论动态预测控制的可行性。
- 以质量指标铁水含硫量[S]为例，含硫量低，铁水质量好，可以生产优质钢，制造优质装备。试建立质量指标[S]的优化数学模型，并且讨论按照优化模型计算结果进行[Si]预测控制的预期效果。
- 讨论你所建立的复杂流程工业智能控制大数据建模的心得体会。

■ 二. 模型假设 ■ ■

- (1) 假设在混沌局部线性预测中，邻域的选取客观准确，主观性较小。
- (2) 假设在混沌局部线性预测中，局部特性可以准确代表整体特性。
- (3) 假设在神经网络预测中，输入变量作为网络的第一层合理有效。
- (4) 假设附件中提供的数据及所使用的数据都真实准确。
- (5) 假设铁水含硅量[Si]、含硫量[S]、喷煤量PML和鼓风量FL组成的数据能代表高炉炼铁过程，体现高炉炼铁特性。

■

三. 符号说明

■

■

符号	说明	符号	说明
σ	标准差	b_j	平移因子
$x_{\min}$	最小值	a_j	伸缩因子
$x_{\max}$	最大值	lr	学习概率
ω_{ij}	连接权值	F	适应度值
θ_j	网络阈值	T	预测步长
y_k	期望输出	τ	滞后时间
$\hat{y}_k$	实际输出	d	嵌入维数
ρ	相关系数	ε	邻域半径

■ 四. 问题分析 ■ ■

4.1 问题一的分析

在问题一中，题目要求我们从给定数据表中[Si]-[S]-FL-PML依序号排列的1000炉生产大数据中，自主选取学习样本和算法，建立[Si]预测动态数学模型，包括一步预测模型和两步预测模型。其中的一步预测模型和两步预测模型指的是预测步长分别取1和2，前后两炉铁水含硅量，即炉温之间是具有相关性的。这里的学习样本不能是全部的1000炉生产大数据，因为问题二中需要验证所建立的数学模型的预测成功率，所以不能选择全部数据来训练，只能选择一部分数据来学习训练。至于建模的算法，需要结合问题本身来选择。

■ 四. 问题分析 ■ ■

4.2 问题二的分析

在问题二中，题目要求我们自主选取验证样本，验证我们所建立的数学模型的预测成功率，包括数值预测成功率和炉温升降方向预测成功率。并且讨论其动态预测控制的可行性。我们需要从1000炉生产大数据中剩下未学习训练的数据中，选取验证样本，验证包括[Si]含量和炉温升降方向的成功率。难点在于讨论其动态预测控制的可行性，以及如何提高算法的预测成功率。

■ 四. 问题分析 ■ ■

4.3 问题三的分析

在问题三中，题目要求我们以质量指标铁水含硫量[S]为例，含硫量低，铁水质量好，可以生产优质钢，制造优质装备。通过大数据挖掘，确定生产过程的最佳途径与最佳参数控制范围，预测性地动态调整生产过程控制，获得最佳生产效果，建立优化模型，并采用智能式启发算法，即全局优化算法，如：遗传算法、粒子群算法、蚁群算法等进行求解，讨论对[Si]的预测控制。

4.4 问题四的分析

在问题四中，题目要求我们讨论我们所建立的复杂流程工业智能控制大数据建模的心得体会，这需要我们模型的结果和背景来讨论。

CONTENTS

目录

一. 问题重述

二. 模型假设

三. 符号说明

四. 问题分析

五. 数据预处理

5.1 异常值剔除

5.2 归一化处理

5.3 预处理后的数据

六. 问题一模型的建立与求解

6.1 BP神经网络预测模型

6.2 小波神经网络预测模型

6.3 遗传算法优化BP神经网络预测模型

6.4 混沌时间序列预测模型



CONTENTS

七. 问题二模型的建立与求解



- 7.1 模型的预测成功率
 - 7.1.1 训练集与验证集
 - 7.1.2 数值预测成功率
 - 7.1.3 炉温升降方向预测成功率
- 7.2 动态预测控制的可行性
 - 7.2.1 神经网络训练函数的选取
 - 7.2.2 神经网络性能参数的设定
 - 7.2.3 混沌时间序列预测的邻域半径



CONTENTS

八. 问题三模型的建立与求解



8.1 遗传算法优化BP神经网络预测S含量

8.1.1 构建预测含硫量[S]的神经网络

8.1.2 含硫量[S]与鼓风量FL和喷煤量PML的关系

8.1.3 含硫量[S]与含硅量[Si]和喷煤量PML的关系

8.1.4 含硫量[S]与含硅量[Si]和鼓风量FL的关系

8.2 粒子群算法优化含硫量[S]

8.2.1 粒子群算法优化流程

8.2.2 粒子群算法优化结果

8.3 [Si]预测控制的预期效果



■ 五. 数据预处理 ■ ■

[Si]含量预测模型的成功率取决于过去[Si]含量数据的质量和数量，由于受到仪表精度、可靠性、现场测量环境、炉温状况及人为因素的影响，“智能控制专家系统”在线采集的数据会存在异常等情况，需剔除不完整和异常数据。如果用这些数据来预测，会导致预测的成功率下降。而且输入变量众多且相互影响，必须对样本数据进行预处理，要对原始数据做异常值剔除、归一化和相关性分析等。

5.1 异常值剔除

如果直接用这些数据来预测，将导致预测的成功率下降，甚至预测结果完全偏离实际值。




图1. 1000炉含硅量[Si]的原始时间序列数据

5.1 异常值剔除

如果直接用这些数据来预测，将导致预测的成功率下降，甚至预测结果完全偏离实际值。




图2. 1000炉含硫量[S]的原始时间序列数据

5.1 异常值剔除

如果直接用这些数据来预测，将导致预测的成功率下降，甚至预测结果完全偏离实际值。




图3. 1000炉鼓风量FL的原始时间序列数据

5.1 异常值剔除

如果直接用这些数据来预测，将导致预测的成功率下降，甚至预测结果完全偏离实际值。




图4. 1000炉喷煤量PML的原始时间序列数据

5.1 异常值剔除

异常值剔除的方法采用的是**拉依达准则**，即 **3σ 准则**：对于1000炉含硅量[Si]、含硫量 [S]、鼓风量 FL 和喷煤量 PML 的原始时间序列数据，**当偏差大于 3σ 的时候，该数据为异常值，需要被及时剔除**， σ 的计算公式为：

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$$

其中， $x_i (i=1 \sim 1000)$ 分别指的是1000炉含硅量[Si]、含硫量[S]、鼓风量FL和喷煤量PML的原始时间序列数据， $\bar{x}$ 分别指的是1000炉含硅量[Si]、含硫量[S]、鼓风量FL和喷煤量PML的原始时间序列数据的平均值，样本容量 $n=1000$ 。

5.1 异常值剔除

当偏差大于 3σ 的时候，该数据为异常值，异常值的判断准则如下：

$$|x_i - \bar{x}| > 3\sigma$$

因此，正常数据的范围为 $x_i > 3\sigma + \bar{x}$ 和 $x_i < \bar{x} - 3\sigma$ ，剔除完剩下的即为正常值。1000炉含硅量[Si]、含硫量[S]、鼓风量FL和喷煤量PML的原始时间序列数据中有**68个异常值**，剔除全部异常值后，**总共剩下932炉次的正常时间序列数据。**

5.2 归一化处理

含硅量[Si]、含硫量[S]、鼓风量FL和喷煤量PML的原始时间序列数据**存在不同的量纲单位，因此数据的大小差别非常大，数据的范围也不相同**。差异的较大会增大某些变量对预测结果的影响，同时会减弱某些变量对预报模型的影响。

所以需要对剔除异常值后的含硅量[Si]、含硫量[S]、鼓风量FL和喷煤量PML的时间序列数据进行归一化。**将所有数据都转化为[0,1]之间的数，可以消除数据因大小不一而造成的偏差，最后对预测结果进行反归一化还原。**

$$x_i' = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

数据的归一化有很多方法，本文采用**最大最小法进行归一化处理**，对含硅量[Si]、含硫量[S]、鼓风量FL和喷煤量PML的数据进行归一化的公式如上所示

5.3 预处理后的数据

经过异常值剔除、数据归一化处理之后得到932炉次的正常时间序列数据，数据见附录。




图5. 预处理后932炉含硅量[Si]的时间序列数据

5.3 预处理后的数据

经过异常值剔除、数据归一化处理之后得到932炉次的正常时间序列数据，数据见附录。




图6. 预处理后932炉含硫量[S]的时间序列数据

5.3 预处理后的数据

经过异常值剔除、数据归一化处理之后得到932炉次的正常时间序列数据，数据见附录。




图7. 预处理后932炉鼓风量FL的时间序列数据

5.3 预处理后的数据

经过异常值剔除、数据归一化处理之后得到932炉次的正常时间序列数据，数据见附录。





图8. 预处理后932炉喷煤量PML的时间序列数据

6.1 BP神经网络预测模型

BP（Back Propagation）神经网络是一种按误差逆传播算法训练的多层前馈网络，通过反向传播来不断调整网络的权值和阈值，使网络的误差平方和最小^[1]。BP神经网络模型拓扑结构包括输入层、隐含层和输出层。



6.1.1 输入层和输出层

BP神经网络的算法具有良好的自适应性和分类识别等能力。神经网络可以看作是一个函数映射，含硅量[Si]的预测可以看成将含硫量[S]、鼓风量FL和喷煤量PML作为输入，含硅量[Si]为输出的复杂函数映射问题。因此，可以利用BP神经网络作为含硅量[Si]的进行预测。下面阐述如何将BP神经网络用于含硅量[Si]的预测。

6.1.2 训练集和验证集


经过异常值剔除和归一化等预处理之后，总共有932炉次的含硅量[Si]、含硫量[S]、鼓风量FL和喷煤量PML，将前922炉次的含硫量[S]、鼓风量FL和喷煤量PML作为学习训练的样本，剩余10炉次的数据作为验证的样本，即：训练集为前 922 炉次的时间序列数据，验证集为后 10 炉次的数据。

6.1.3 三层BP神经网络结构

三层BP网络输入节点为 m 个（与 p 同维），输出节点为 c 个，隐节点为 r 个，输入层到隐层的激活函数采用 Sigmoid 型函数，隐含层到输出层的激活函数采用线性函数 Purelin 函数，可得网络输入与输出的关系如下所示^[1]:

$$\hat{y}_k = \sum_{j=1}^r v_j \cdot f \left[\sum_{i=1}^m w_{ij} \cdot P_i + \theta_j \right] \quad (k=1,2,\dots,N)$$

将含硫量[S]、鼓风量FL和喷煤量 PML 作为输入层，将含硅量[Si]作为输出层。



6.1.4 BP神经网络的参数

BP神经网络时间序列预测模型中的参数主要包括：最大训练步数 `net.trainParam.epochs`、训练结果的间隔步数 `net.trainParam.show`、学习速率 `net.trainParam.lr`、动子因量 `net.trainParam.mc`、训练目标误差 `net.trainParam.goal`，本文中设置的BP神经网络预测模型中的参数如下表所示：

表 1. BP 神经网络预测模型中的参数

最大训练步数	训练结果的间隔步数	学习速率	动子因量	训练目标误差
50000	2000	0.45	0.8	0.0000001

6.1.5 BP神经网络预测的结果

BP神经网络预测的结果如图11所示，从图11中看出预测的效果不是很好。




图11. BP神经网络预测的结果

6.1.5 BP神经网络预测的结果

BP神经网络预测的结果如图11所示，从图11中看出预测的效果不是很好。




图12. BP神经网络预测验证10炉次的预测值与实际值

6.1.5 BP神经网络预测的结果

Best Training Performance is 0.0072643 at epoch 50000




图13. BP神经网络预测模型的性能曲线

6.1.5 BP神经网络预测的结果




图14. BP神经网络预测模型的梯度和验证

6.1.5 BP神经网络预测的结果




图15是BP神经网络预测模型的回归效果，**相关系数R只有0.44658**，说明了传统的BP神经网络对于高炉炼铁过程中含硅量[Si]的预测不是很准确。

因此，**需要对传统的BP神经网络预测模型进行改进，提高其预测效果。**

图15. BP神经网络预测模型的回归效果

6.1.6 相关性分析

为了研究含硫量 [S]、鼓风量FL和喷煤量 PML与含硅量[Si]之间的相关性，本文计算了不同指标之间的**Pearson线性相关系数**，计算公式如下^[2]：

$$\rho = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

表 2. 含硅量[Si]、含硫量[S]、鼓风量 FL 和喷煤量 PML 之间的相关系数

相关系数	含硅量[Si]	含硫量[S]	鼓风量 FL	喷煤量 PML
含硅量[Si]	1.0000	-0.2131	-0.0219	-0.0180
含硫量[S]	-0.2131	1.0000	-0.0640	-0.0002
鼓风量 FL	-0.0219	-0.0640	1.0000	0.3883
喷煤量 PML	-0.0180	-0.0002	0.3883	1.0000

含硫量[S]与含硅量[Si]的相关性比鼓风量 FL与含硅量 [Si]、喷煤量PML与含硅量[Si]的相关性更大，鼓风量FL与喷煤量 PML 之间的相关性最大。

6.2 小波神经网络预测模型

小波神经网络是由小波理论和神经网络理论相互作用的结果，其实质是用小波元取代神经元。小波神经网络模型的网络拓扑结构如图16所示^[2]。




图16. 小波神经网络模型的网络拓扑结构

6.2.1 小波神经网络的结构

在图 16 中， x_i 代表小波网络模型的输入变量，即含硫量[S]、鼓风量 FL 和喷煤量 PML 作为输入层。 y 代表小波网络模型的预测输出，即含硅量[Si]，小波网络模型的权值是 ω_{ij} 和 ω_j 。

在输入变量时，隐含层输出表达式如下[2]：

$$h(j) = h_j \left(\frac{\sum_{i=1}^k \omega_{ij} x_i - b_j}{a_j} \right)$$

其中， $h(j)$ 表示隐含层的第 j 个节点输出， ω_{ij} 是输入层与隐含层的权值，小波基函数 h_j 的平移因子和伸缩因子分别为 b_j 和 a_j 。

6.2.2小波神经网络的基函数

Morlet母小波基函数的表达式为：

$$y = \cos(1.75x) e^{-x^2/2}$$

Morlet母小波基函数的导函数表达式为：

$$y = -1.75 \sin(1.75x) e^{-x^2/2} - x \cos(1.75x) e^{-x^2/2}$$

小波网络模型的输出层计算公式如下^[2]：

$$y = \sum_{i=1}^l \omega_i h(i)$$

6.2.3 小波神经网络的流程

小波网络模型的修正算法与BP神经网络模型基本相同，均采用梯度下降法来修正网络模型的权值，使小波神经网络模型的预测输出结果不断逼近期望的输出值。

- **网络模型的初始化：**首先需要初始化小波函数的伸缩因子、平移因子、网络的学习速率和网络的连接权重。
- **仿真数据的分类：**把高炉炉温数据分为训练部分和测试部分，训练数据用于训练网络，测试数据则是用于测试网络的预测精度。
- **预测结果输出：**把高炉铁水温度训练数据输入网络，计算出网络模型的预测输出，并计算网络模型输出与期望输出之间的误差。
- **权值的修正：**由误差在线修正网络模型的权值和小波网络模型参数。最后判断算法是否结束，如果没有结束，则返回步骤3。
- **模型的仿真验证：**小波神经网络预测模型的仿真验证。

6.2.4 小波神经网络的参数


BP神经网络预测模型中的参数主要包括隐形节点个数、学习概率 lr_1 、学习概率 lr_2 和迭代次数 n ，本文中设置的BP神经网络预测模型中的参数如下表所示。

表 3. BP 神经网络预测模型中的参数

隐形节点个数	学习概率	学习概率	迭代次数
6	0.01	0.001	1000

6.2.5 小波神经网络的结果

小波神经网络模型预测的结果如图17所示，从图17中可以看出，小波神经网络模型预测值与实际值比较接近，这比BP神经网络预测效果要好，因为小波神经网络的局部搜索特性和收敛速度快，从而取得精确度较高的预测结果。



6.3 遗传算法优化BP神经网络预测模型

遗传算法是一种并行随机搜索优化方法。遗传算法优化BP网络，包括BP神经网络结构的确定、遗传算法的优化和BP神经网络的预测三部分内容^[3]。




图 18. 遗传算法优化 BP 神经网络模型的拓扑结构



6.3.2 预测模型的流程

遗传算法GA优化BP神经网络是指**利用遗传算法优化BP网络的初始权值和阈值，优化后的BP网络能够取得更好的预测输出**^[3]。遗传算法GA优化BP网络的主要步骤如下：

- **种群初始化：**每个个体的编码方法选择实数编码方式。其中，每个个体包含了全部的网络权值和阈值。在高炉炼铁输入输出变量已知的情况下，便能构成一个网络结构、权值和阈值确定的网络。
- **适应度函数：**首先由每个个体可以得到BP神经网络算法的初始权值和阈值。接着用训练数据训练BP网络后，从而得到系统的预测值。把预测值和期望值之间的误差绝对值作为个体的适应度值F，计算公式如下：

$$F = k \sum_{i=1}^n |y_i - o_i|$$

其中， n 是网络的输出节点， y_i 是 BP 神经网络第 i 个节点的期望输出， o_i 为第 i 个节点的预测输出， k 是系数。

6.3.2 预测模型的流程

- **选择操作：**本文选择操作方法是采用**适应度比例法**，计算公式如下^[3]：

$$f_i = k / F_i, \quad P_i = \frac{f_i}{\sum_{j=1}^N f_j}$$

其中，个体 i 的适应度值为 F_i ， k 为系数， N 为种群个体的总数。

- **交叉操作：**个体选用实数编码。第 k 个染色体 a_k 和第 l 个染色体 a_l 在 j 位的交叉操作公式为^[3]：

$$\begin{cases} a_{kj} = a_{kj}(1-b) + a_{lj}b \\ a_{lj} = a_{lj}(1-b) + a_{kj}b \end{cases}$$

其中， b 是 $[0, 1]$ 之间的任意数。

6.3.2 预测模型的流程

- **变异操作：**选取第 i 个个体的第 j 个基因 a_{ij} 进行变异操作，其公式为^[3]:

$$a_{ij} = \begin{cases} a_{ij} + (a_{ij} - a_{\min})f(g) & r \geq 0.5 \\ a_{ij} + (a_{\min} - a_{ij})f(g) & r < 0.5 \end{cases}$$

其中，基因 a_{ij} 的上限是 $a_{\max}$ ，基因 a_{ij} 的下限是 $a_{\min}$ ， $f(g) = r_2(10g/G_{\max})$ ， r_2 是一个任意数， g 是当前的迭代次数， $G_{\max}$ 是最大进化次数， r 是 $[0, 1]$ 之间的任意数。

- **BP网络部分：**遗传算法部分获取最优权值与阈值。通过计算误差的网络学习算法，实时更新权值和阈值，最终取得优化结果。
- **仿真校验：**遗传算法优化BP神经网络的仿真校验。

6.3.3 预测模型的参数


遗传算法优化BP神经网络预测模型中的参数主要包括种群规模数、进化次数、交叉概率和变异概率，本文中设置BP神经网络预测模型中的参数如表所示：

表 4. 遗传算法优化 BP 神经网络预测模型中的参数

种群规模数	进化次数	交叉概率	变异概率
10	50	0.4	0.2

6.3.4 预测模型的结果

因为基于遗传算法优化BP神经网络的多元时间序列模型，其预测结果因考虑了变量的时滞，因此预测结果误差较小。



6.3.4 预测模型的结果

训练集为前922炉次的时间序列数据，验证集为后10炉次的数据。




图 20. 遗传算法优化 BP 神经网络预测模型验证 10 炉次的预测值与实际值

6.3.4 预测模型的结果




图 21. 遗传算法优化 BP 神经网络预测模型的性能曲线

6.3.4 预测模型的结果




图 22. 遗传算法优化 BP 神经网络预测模型的梯度和验证

6.3.4 预测模型的结果





图23是遗传算法优化BP神经网络预测模型的回归效果，**相关系数 R 为0.99993**，说明了基于遗传算法对BP神经网络进行改进之后，可以大大提高BP神经网络预测[Si]含量的准确性。

图 23. 遗传算法优化 BP 神经网络预测模型的回归效果

6.3.4 预测模型的结果



虽然基于遗传算法优化的BP神经网络能提高网络的训练速度。但是，遗传算法复杂的操作过程，使网络的搜索时间随着所研究问题复杂度不同呈指数倍增长。遗传算法缺少局部搜索特性，该算法在得到最优解时收敛缓慢也有可能出现收敛停止问题。

因此本文又建立了混沌时间序列预测模型来预测[Si]含量。

6.4 混沌时间序列预测模型

郜传厚指出高炉炼铁的过程中的**含硅量[Si]**貌似是随机的，实际上并不是随机的，而是混沌的^[4]。由于混沌局部线性一步、二步预测含硅量[Si]，取得了很好的效果，因此本文建立了**混沌时间序列预测**模型来动态预测含硅量[Si]。

对于高炉炼铁混沌时间序列 $\{X_t\}$ ， $t=1, 2, \dots, n$ ，利用相空间重构技术^[4]和 Takens 定理^[5]，嵌入维数为 d ，时滞为 τ ，重构相空间中的矢量点可表示为^[5]：

$$X_t = (x_t, x_{t+\tau}, \dots, x_{t+(d-1)\tau})^T$$

根据**非线性动力学**，建立**混沌时间序列预测模型**，可以对含硅量[Si]进行**混沌局部线性一步预测和二步预测**。

6.4.1 一步预测模型

假设预测步长为 T ，对于含硅量[Si]的一步预测， $T=1$ ，根据 Takens 定理，可以建立混沌时间序列的预测模型，即^[5]：

$$X_{t+1} = f(X_t)$$

混沌局部线性预测模型可以表示为^[5]：

$$X_{t+1} = aX_t + bI$$

其中， a 和 b 是拟合系数， I 是各分量均为 1 的 d 维列向量。

对于高炉炼铁的混沌时间序列的 X_p ，在重构相空间的矢量点中，选取一定的邻域半径 ε ，找出邻近 X_p 的 k 个矢量点， X_{p1} ， X_{p2} ，……， X_{pk} ，使得满足：

$$|X_{pj} - X_p| \leq \varepsilon$$

6.4.1 一步预测模型

定义 ξ_i 和 ξ_p 如下^[5]:

$$P = \frac{1}{k} \sum_{i=1}^k X_{Pi}, \quad \xi_i = X_{Pi} - P, \quad \xi_p = X_p - P$$

对于 k 个矢量点的一步迭代点 $X_{P1+1}, X_{P2+1}, \dots, X_{Pk+1}$, 定义^[5]:

$$\tilde{P} = \frac{1}{k} \sum_{i=1}^k X_{Pi+1}, \quad \tilde{\xi}_i = X_{Pi+1} - \tilde{P}, \quad \tilde{\xi}_p = X_{P+1} - \tilde{P}$$

使用混沌局部线性预测模型拟合这 k 个矢量点的迭代情况, 即满足^[6]:

$$\tilde{\xi}_i \approx a\xi_i + bI$$

6.4.1 一步预测模型

使用最小二乘法可以拟合出 a 和 b 拟合系数，即最小化误差：

$$\min E = \min \frac{1}{k} \sum_{i=1}^k \left| \tilde{\xi}_i - a\xi_i - bI \right|^2$$

令误差 E 对拟合系数 a 和 b 的偏导数为 0，即满足：

$$\frac{\partial E}{\partial a} = 0, \quad \frac{\partial E}{\partial b} = 0$$

6.4.1 一步预测模型

可以求解得到拟合系数 a 的计算公式为^[6]:

$$a = \frac{\left(\sum_{i=1}^k \tilde{\xi}_i^T I \right) \left(\sum_{i=1}^k I^T \xi_i \right) - \left(\sum_{i=1}^k \tilde{\xi}_i^T \xi_i \right) \left(\sum_{i=1}^k I^T I \right)}{\left(\sum_{i=1}^k I^T \xi_i \right)^2 - \left(\sum_{i=1}^k \tilde{\xi}_i^T \xi_i \right) \left(\sum_{i=1}^k I^T I \right)}$$

可以求解得到拟合系数 b 的计算公式为^[6]:

$$b = \frac{\left(\sum_{i=1}^k \tilde{\xi}_i^T \xi_i \right) \left(\sum_{i=1}^k I^T \xi_i \right) - \left(\sum_{i=1}^k \tilde{\xi}_i^T I \right) \left(\sum_{i=1}^k I^T I \right)}{\left(\sum_{i=1}^k I^T \xi_i \right)^2 - \left(\sum_{i=1}^k \tilde{\xi}_i^T \xi_i \right) \left(\sum_{i=1}^k I^T I \right)}$$

然后根据以下公式可以计算出矢量 $\tilde{\xi}_p$ ，从而可以求出 X_{p+1} ^[6]: $\tilde{\xi}_p = a\xi_p + bI$

6.4.2 一步预测的参数


在混沌局部线性预测模型中，对于含硅量[Si]的一步预测，本文设置一步预测的参数如下表所示^[7]：

表 5. 一步预测的参数

步长 T	滞后时间 τ	嵌入维数 d	邻域半径 ε
1	6	8	0.35

6.4.3 一步预测的结果

混沌局部线性一步预测的结果如图 24 所示, 从图 24 中可以看出, 预测值与实际值分布在直线 $x_{n+1} = x_n$ 附近, 即预测值和实际值有很好的对应关系。计算得到预测命中率在 $[Si] \pm 0.1\%$ 的范围内分别为 84.5% 和 83.2%。



- 通过计算预测相对误差, 混沌局部线性一步预测模型的精度, 计算公式为:

$$E = \frac{\sum_{i=1}^n (x_i' - x_i)^2}{\sum_{i=1}^n x_i^2}$$

- 计算得混沌局部线性一步预测模型的精度为 **0.0127**, 对生产有很好的作用。

6.4.4 二步预测模型

假设预测步长为 T ，对于含硅量[Si]的二步预测， $T=2$ ，根据 Takens 定理，可以建立混沌时间序列的预测模型，即^[7]：

$$X_{t+2} = f(X_t)$$

混沌局部线性预测模型可以表示为^[7]：

$$X_{t+2} = aX_t + bI$$

其中， a 和 b 是拟合系数， I 是各分量均为 1 的 d 维列向量。

6.4.5 二步预测的参数


在混沌局部线性预测模型中，对于含硅量[Si]的二步预测，本文设置参数如下表所示^[7]：

表 6. 二步预测的参数

步长 T	滞后时间 τ	嵌入维数 d	邻域半径 ε
2	6	7	0.26

6.4.6 二步预测的结果

混沌局部线性一步预测的结果如图 25 所示, 从图 25 中可以看出, 预测值与实际值分布在直线 $x_{n+1} = x_n$ 附近, 即预测值和实际值有很好的对应关系。计算得到预测命中率在 $[Si] \pm 0.1\%$ 的范围内分别为 84.6% 和 85.1%。



- 通过计算预测相对误差, 混沌局部线性二步预测模型的精度, 计算公式为:

$$E = \frac{\sum_{i=1}^n (x_i' - x_i)^2}{\sum_{i=1}^n x_i^2}$$

- 计算得混沌局部线性二步预测模型的精度为 **0.0245**, 对生产有很好的作用。

七. 问题二模型的建立与求解

7.1 模型的预测成功率

7.1.1 训练集与验证集

经过异常值剔除和归一化等预处理之后，总共有932炉次的含硅量[Si]、含硫量[S]、鼓风量FL和喷煤量PML，将前922炉次的含硫量[S]、鼓风量FL和喷煤量PML作为学习训练的样本，剩余10炉次的数据作为验证的样本，即：

训练集为前 922 炉次的时间序列数据，验证集为后10炉次的数据。

然后，验证本文所建立的数学模型的预测成功率，**包括数值预测成功率和炉温升降方向预测成功率**，验证结果见下文。

7.1.2 数值预测成功率

传统的BP神经网络预测模型、小波神经网络模型预测模型、基于遗传算法优化BP神经网络预测模型和混沌时间序列预测模型，分别预测后10炉次含硅量[Si]的结果与实际值的对比如图26~图29所示。




图 26. BP 神经网络预测验证后 10 炉次的预测值与实际值

7.1.2 数值预测成功率




图 27. 小波神经网络预测验证后 10 炉次的预测值与实际值

7.1.2 数值预测成功率




图 28. 遗传算法优化 BP 神经网络预测模型验证后 10 炉次的预测值与实际值

7.1.2 数值预测成功率




图 29. 混沌时间序列预测模型验证后 10 炉次的预测值与实际值

7.1.2 数值预测成功率

不同预测模型预测后 10 炉次含硅量的结果与实际值的数据如表 7 所示。

表 7. 不同预测模型预测后 10 炉次含硅量的结果与实际值的对比

序号	炉次	实际含硅量[Si]	BP 预测	小波预测	GA+BP 预测	混沌预测
1	991	0.3714	0.2382	0.3730	0.3710	0.3713
2	992	0.4476	0.2435	0.4466	0.4477	0.4489
3	993	0.2952	0.2551	0.2957	0.2952	0.2948
4	994	0.3143	0.2341	0.3150	0.3146	0.3151
5	995	0.1333	0.2495	0.1329	0.1326	0.1334
6	996	0.0857	0.2439	0.0881	0.0870	0.0858
7	997	0.2857	0.3732	0.2861	0.2863	0.2856
8	998	0.2190	0.2724	0.2180	0.2168	0.2228
9	999	0.2381	0.2244	0.2375	0.2375	0.2389
10	1000	0.1619	0.2659	0.1606	0.1599	0.1633

7.1.2 数值预测成功率

从图 26~图 29 中可以看出，基于遗传算法优化 BP 神经网络预测模型和混沌时间序列预测模型的预测效果很好，小波神经网络模型预测模型的预测效果较好，传统的 BP 神经网络预测模型较差。

为了计算不同预测模型的预测命中率，即**数值预测成功率**，我们定义如下：

- 如果预测结果在实际含硅量 $[\text{Si}] \pm 0.5\%$ **范围之内**，则认为 **预测成功**；
- 如果预测结果在实际含硅量 $[\text{Si}] \pm 0.5\%$ **范围之外**，则认为 **预测失败**。

7.1.2 数值预测成功率

从表8中可以看出，在10次预测验证的情况中，**只有2次预测成功**。因此传统的BP神经网络预测模型的数值预测成功率大约在**20%**左右，预测效果较差。

表 8. 传统的 BP 神经网络预测模型的预测情况

序号	炉次	实际[Si]-0.5%	实际	实际[Si]+0.5%	BP	绝对误差	相对误差	预测情况
1	991	0.3696	0.3714	0.3733	0.2382	-0.1332	0.3587	×
2	992	0.4454	0.4476	0.4499	0.2505	-0.1971	0.4404	×
3	993	0.2938	0.2952	0.2967	0.2481	-0.0471	0.1597	×
4	994	0.3127	0.3143	0.3159	0.2501	-0.0642	0.2042	×
5	995	0.1327	0.1333	0.1340	0.2514	0.1181	0.8855	×
6	996	0.0853	0.0857	0.0861	0.2358	0.1501	1.7510	×
7	997	0.2843	0.2857	0.2871	0.3732	0.0875	0.3062	×
8	998	0.2180	0.2190	0.2201	0.1684	-0.0506	0.2312	×
9	999	0.2369	0.2381	0.2393	0.2382	0.0001	0.0004	√
10	1000	0.1611	0.1619	0.1627	0.1623	0.0004	0.0024	√

7.1.2 数值预测成功率

从表9中可以看出，在10次预测验证的情况中，有7次预测成功。因此小波神经网络预测模型的数值预测成功率大约在70%左右，预测效果较好。

表 9. 小波神经网络预测模型的预测情况

序号	炉次	实际[Si]-0.5%	实际	实际[Si]+0.5%	小波预测	绝对误差	相对误差	预测情况
1	991	0.3696	0.3714	0.3733	0.3730	0.0016	0.0042	√
2	992	0.4454	0.4476	0.4499	0.4466	-0.0010	0.0023	√
3	993	0.2938	0.2952	0.2967	0.2957	0.0004	0.0014	√
4	994	0.3127	0.3143	0.3159	0.3150	0.0007	0.0021	√
5	995	0.1327	0.1333	0.1340	0.1329	-0.0005	0.0036	√
6	996	0.0853	0.0857	0.0861	0.0881	0.0024	0.0276	×
7	997	0.2843	0.2857	0.2871	0.2861	0.0003	0.0012	√
8	998	0.2180	0.2190	0.2201	0.2179	-0.0011	0.0052	×
9	999	0.2369	0.2381	0.2393	0.2375	-0.0006	0.0024	√
10	1000	0.1611	0.1619	0.1627	0.1606	-0.0013	0.0078	×

7.1.2 数值预测成功率

从表10中可以看出，在10次预测验证的情况中，有6次预测成功。因此基于遗传算法优化BP神经网络预测模型数值预测成功率大约在 60% 左右。

表 10. 基于遗传算法优化 BP 神经网络预测模型的预测情况

序号	炉次	实际[Si]-0.5%	实际	实际[Si]+0.5%	GA+BP	绝对误差	相对误差	预测情况
1	991	0.3696	0.3714	0.3733	0.3710	-0.0004	0.0012	√
2	992	0.4454	0.4476	0.4499	0.4477	0.0001	0.0002	√
3	993	0.2938	0.2952	0.2967	0.2952	0.0000	0.0001	√
4	994	0.3127	0.3143	0.3159	0.3146	0.0003	0.0010	√
5	995	0.1327	0.1333	0.1340	0.1326	-0.0007	0.0055	×
6	996	0.0853	0.0857	0.0861	0.0870	0.0013	0.0150	×
7	997	0.2843	0.2857	0.2871	0.2863	0.0006	0.0020	√
8	998	0.2180	0.2190	0.2201	0.2168	-0.0022	0.0103	×
9	999	0.2369	0.2381	0.2393	0.2375	-0.0006	0.0025	√
10	1000	0.1611	0.1619	0.1627	0.1599	-0.0020	0.0124	×

7.1.2 数值预测成功率

从表11中可以看出，在10次预测验证的情况中，有8次预测成功。因此混沌时间序列预测模型的数值预测成功率大约在80%左右，预测效果较好。

表 11. 混沌时间序列预测模型的预测情况

序号	炉次	实际[Si]-0.5%	实际	实际[Si]+0.5%	混沌	绝对误差	相对误差	预测情况
1	991	0.3696	0.3714	0.3733	0.3713	-0.0001	0.0003	√
2	992	0.4454	0.4476	0.4499	0.4489	0.0013	0.0029	√
3	993	0.2938	0.2952	0.2967	0.2948	-0.0004	0.0015	√
4	994	0.3127	0.3143	0.3159	0.3151	0.0008	0.0026	√
5	995	0.1327	0.1333	0.1340	0.1334	0.0001	0.0005	√
6	996	0.0853	0.0857	0.0861	0.0858	0.0001	0.0010	√
7	997	0.2843	0.2857	0.2871	0.2856	-0.0001	0.0004	√
8	998	0.2180	0.2190	0.2201	0.2228	0.0038	0.0171	×
9	999	0.2369	0.2381	0.2393	0.2389	0.0008	0.0034	√
10	1000	0.1611	0.1619	0.1627	0.1633	0.0014	0.0086	×

7.1.3 炉温升降方向预测成功率

至于不同模型的炉温升降方向预测成功率，只需要与实际的炉温升降情况对比，即可计算出炉温升降方向预测成功率。

表 12. 不同模型预测炉温升降方向的结果

序号	炉次	实际含硅量[Si]	实际升降温	BP 预测	小波预测	GA+BP 预测	混沌预测
1	991	0.3714	/	/	/	/	/
2	992	0.4476	升温	升温	升温	升温	升温
3	993	0.2952	降温	升温	降温	降温	降温
4	994	0.3143	升温	降温	升温	升温	升温
5	995	0.1333	降温	升温	降温	降温	降温
6	996	0.0857	降温	降温	降温	降温	降温
7	997	0.2857	升温	升温	升温	升温	升温
8	998	0.2190	降温	降温	降温	降温	降温
9	999	0.2381	升温	降温	升温	升温	升温
10	1000	0.1619	降温	升温	降温	降温	降温

7.1.3 炉温升降方向预测成功率

综上，不同的预测模型分别预测后10炉次含硅量[Si]的数值预测成功率和炉温升降方向预测成功率如表13所示。

表 13. 不同模型预测炉温升降方向的结果

预测成功率	BP 预测	小波预测	GA+BP 预测	混沌预测
数值预测成功率	20 %	70 %	60 %	80 %
炉温升降方向预测成功率	40 %	100 %	100 %	100 %

- 在预测含硅量[Si]数值方面，四种模型的预测成功率从高到低分别为：
- 混沌预测 > 小波预测 > 遗传算法优化BP神经网络预测 > 传统的BP神经网络
- 在预测炉温升降方向方面，后面三种模型的预测成功率都非常高，而传统的BP神经网络预测只有 40 %的正确率，远远小于其余三种预测模型；

7.2 动态预测控制的可行性

7.2.1 神经网络训练函数的选取

当采用一般的基于梯度下降的BP神经网络进行训练时，由于固定的学习速率，有限的迭代次数，较小的设定误差和截止梯度，致使BP神经网络有较长的训练时间，而且还不一定能达到要求的精度，这会大大影响识别率^[9]。

经过多次训练函数的尝试，最终选择带有动量相的自适应学习率的训练函数 **traingdx**。不同训练函数在训练速度上的比较见表14。

7.2.1 神经网络训练函数的选取

表 14. 神经网络训练参数对识别率的影响

隐层节点数	截止误差	学习速率	训练函数	迭代次数	时间/s	预测成功率
50	0	0.1	traingdx	768	5	82.5%
60	0	0.1	traingdx	823	5	77.5%
70	0	0.1	traingdx	718	5	80.0%
50	0	0.2	traingdx	404	5	85.0%
60	0	0.2	traingdx	195	1	81.3%
70	0	0.2	traingdx	194	1	78.8%
50	0.001	0.2	traingdm	10000	88	80.0%
60	0.001	0.2	traingdm	10000	99	92.5%
70	0.001	0.2	traingdm	4385	54	93.8%

尽管采用添加动量相的神经网络预测算法，由于学习速率固定，网络的训练速度仍旧很慢。如果盲目的增加学习速率，又会造成网络在某处的波动。

7.2.2 神经网络性能参数的设定

为了缩短运行时间，通过加大截止误差（`trainParam.goal`）和设定迭代次数（`trainParam.epochs`）的方法来加快程序运行，这样会在一定程度上降低预测成功率。

当采用 `traingdx` 的训练函数后，网络运行速度加快，将截止误差（`trainParam.goal`）设定为0，迭代次数（`trainParam.epochs`）仍设定为10000，发现每次促使训练停止的为默认的截止梯度，此时的网络误差已足够小。

7.2.3 混沌时间序列预测的邻域半径

虽然基于混沌时间序列预测含硅量[Si]的数值预测成功率和炉温升降方向预测成功率都较高，但是其中**邻域半径的选择**对于结果有很大的影响。

目前，**邻域半径的选择具有主观性**^[10]。如果**通过基于递归分析对邻域半径进行参数估计或基于噪声强度对邻域半径进行参数估计**，可以增加客观性，使得邻域半径的选择更加科学有效。

综上，本文建立的几种改进的模型在动态预测控制方面，具有可行性，参数的调节可以提高预测成功率，几种改进后模型的预测效果很好。

■ 八. 问题三模型的建立与求解 ■ ■

■ 8.1 遗传算法优化BP神经网络预测S含量 ■ ■

■ 8.1.1 构建预测含硫量[S]的神经网络

在问题二中，建立了基于遗传算法优化BP神经网络预测Si含量。同理，可以**基于遗传算法优化BP神经网络预测S含量**。

经过异常值剔除和归一化等预处理之后，总共有932炉次的含硅量[Si]、含硫量[S]、鼓风量FL和喷煤量PML，**将前922炉次的含硅量[Si]、鼓风量FL和喷煤量PML作为学习训练样本的输入量，含硫量[S]作为输出量**。然后，用此网络来预测不同含硅量[Si]、鼓风量FL和喷煤量PML时的含硫量[S]，如图30所示。

8.1.1 构建预测含硫量[S]的神经网络




图 30. 基于遗传算法优化 BP 神经网络预测含硫量[S]的结果

8.1.2 含硫量[S]与鼓风量FL和喷煤量PML的关系




图 31. 含硫量[S]与鼓风量 FL 和喷煤量 PML 的关系

8.1.3 含硫量[S]与含硅量[Si]和喷煤量PML的关系




图 32. 含硫量[S]与含硅量[Si]和喷煤量 PML 的关系

8.1.4 含硫量[S]与含硅量[Si]和鼓风量FL的关系




图 33. 含硫量 $[S]$ 与含硅量 $[Si]$ 和鼓风量 FL 的关系

8.2 粒子群算法优化含硫量[S]

8.2.1 粒子群算法优化流程

粒子群算法优化含硫量[S]的主要步骤如下所示：

- 随机初始化粒子群、群体规模和每个粒子群体的位置和速度：通常在允许的范围内随机设置微粒的初始位置和速度，每个微粒的 $pbest$ 设为其初始位置， $pbest$ 中的最好值设为 $gbest$ ；
- 计算每个粒子的适应值，计算每个微粒的目标函数；
- 对每个粒子，将其适应值与个体极值 $pbest$ 进行比较，如果较优于 $pbest$ ，则将其作为当前的最好位置 $pbest$ ；

8.2 粒子群算法优化含硫量[S]

8.2.1 粒子群算法优化流程

- 对每个粒子，将其适应度值与全局极值 $gbest$ 进行比较，如果优于 $gbest$ ，则将其作为群体的最优位置，并重新设置 $gbest$ 的索引号；
- 每一代粒子根据下面公式更新自己的速度和位置^[12]：

$$v_i^{k+1} = \omega v_i^k + c_1 \times rand() \times (pbest - x_i^k) + c_2 \times rand() \times (gbest - x_i^k)$$

$$x_i^{k+1} = x_i^k + \alpha v_i^{k+1}$$

其中， ω 为惯性权重， c_1 和 c_2 是学习因子， r_1 和 r_2 是 $[0,1]$ 之间的随机数。

- 如果满足结束条件（误差足够好或达到最大循环次数）退出，否则回到步骤2，继续搜索。

8.2.2 粒子群算法优化结果

当鼓风量归一化后 $FL=0.7012$ 和喷煤量 $PML=0.0809$ 时，含硫量 $[S]$ 有最小值。





图 34. 含硫量 $[S]$ 与鼓风量 FL 和喷煤量 PML 的关系

8.3 [Si]预测控制的预期效果

按照粒子群优化含硫量[S]模型的计算结果进行含硅量[Si]预测控制，预测到此时含硅量[Si]为 **0.5712**，此时的含硅量[Si]较小。




当鼓风量归一化后 $FL=0.7012$ 和喷煤量 $PML=0.0809$ 时，含硫量[S]有最小值。

此时，将含硫量[S]、鼓风量FL和喷煤量PML作为神经网络的输入量，可以预测出此时的含硅量[Si]。

8.3 [Si]预测控制的预期效果

- 当鼓风量FL较大，喷煤量PML较小时，含硫量[S]较小，同时，含硅量[Si]较小。含硅量[Si]可以被动态预测控制。
- 通过调节鼓风量FL和喷煤量PML可以调节含硅量[Si]。



九. 问题四的心得体会

- 高炉炼铁的复杂生产工业流程中，其生产过程的系统优化与智能控制的目标函数包括优质，低耗，绿色环保等多目标要求。而充分利用生产工艺大数据的信息物理系统建模，**通过大数据挖掘确立最佳生产途径和最佳参数控制范围是优化生产流程，聚合生产资源，提高生产效能的关键所在。**
- 同时，实现对高炉炉温的预测和控制则是控制高炉复杂系统的难点所在。相关文献通过**计算饱和关联维数定量地证明高炉等高炉冶炼过程具有混沌性，这为将混沌时间序列预测模型应用于高炉的[Si]预测提供理论依据。**
- **通过利用混沌局部线性预测模型，对高炉[Si]进行混沌局部线性一步预测与二步预测，取得了很好的预测效果。**同时，通过建立[Si]含量的BP神经网络预测模型，利用实际生产数据进行仿真验证，结果表明该模型能对高炉喷煤冶炼过程中的铁水[Si]含量进行实时有效预测。

九. 问题四的心得体会

- 此外，通过利用**多元线性回归计算模型**，也对高炉冶炼中[Si]含量具有很好的预测效果。在本次复杂流程工业智能控制大数据建模中，**我们深刻体会到随着大数据技术与工业制造技术的发展，现代工业过程聚合程度日益提高，系统呈现出高度智能化和高度自动化。**
- 由于工业生产普遍存在**非线性和动态特性**，随着大数据智能化的发展，对于此类复杂系统，其控制已逐渐由传统的反馈分析控制过渡到通过炉温预测实时控制。
- 此外，[S]含量也是衡量冶铁质量优劣的重要指标，[S]越低，冶铁质量越好。在出铁之前了解铁水中的含硫量的高低对于高炉生产具有一定指导意义。第（3）问中，**基于遗传算法（GA）和BP神经网络构造高炉铁水含硫量的预测分析模型，对高炉冶炼炉况数据进行预测，预测精度较高。**

九. 问题四的心得体会

- 随着人类文明日新月异的发展，科技是第一生产力的最佳例证，更是科技革新起源于生产实践，技术革新推动工业进步的重大突破。
- 同时，该模型回归分析了高炉喷煤量PML和风量FL与铁水硫含量的相关关系，优化结果与高炉理论基本吻合，可为高炉生产提供一定的指导。当鼓风量归一化后**FL=0.7012**和**喷煤量PML=0.0809**时，含硫量[S]有最小值。
- 此时，将含硫量[S]、鼓风量FL和喷煤量PML作为神经网络的输入量，**可以预测出此时的含硅量[Si]为 0.5712，此时含硅量[Si]较小。通过调节鼓风量FL和喷煤量PML可以调节含硅量[Si]和含硫量[S]。**
- 虽然基于遗传算法优化的BP神经网络能提高网络的训练速度。但是，遗传算法复杂的操作过程，使网络的搜索时间随着所研究问题复杂度不同呈指数倍增长。**遗传算法在得到最优解时收敛缓慢也有可能收敛停止问题。**

十. 结论

基于遗传算法优化BP神经网络模型和混沌时间序列预测模型的预测效果很好，小波神经网络模型预测模型的效果较好，传统的BP神经网络模型较差。

表 15. 不同模型预测炉温升降方向的结果

预测成功率	BP 预测	小波预测	GA+BP 预测	混沌预测
数值预测成功率	20 %	70 %	60 %	80 %
炉温升降方向预测成功率	40 %	100 %	100 %	100 %

当鼓风量归一化后 $FL = 0.7012$ 和喷煤量 $PML = 0.0809$ 时，含硫量[S]有最小值。此时，将含硫量[S]、鼓风量FL和喷煤量PML作为神经网络的输入量，可以预测出此时的含硅量 [Si]为 0.5712 ，此时含硅量[Si]较小。通过调节鼓风量FL和喷煤量PML可以调节含硅量[Si]和含硫量[S]。

摘要

在我国制造业升级“中国制造2025”的国家战略下，为了预测控制高炉炼铁过程，本文建立了神经网络预测模型、混沌时间序列预测模型，并基于遗传算法（GA）改进了神经网络模型，使用粒子群算法（PSO）优化了含硫量[S]。

针对问题一，首先，本文对附件所给数据进行了数据预处理，剔除了异常值并归一化，得到932组有效数据。然后，建立BP神经网络预测模型预测了含硅量[Si]，并分析了含硅量[Si]、含硫量[S]、鼓风量FL和喷煤量PML之间的相关性。其次，建立了小波神经网络预测模型和遗传算法（GA）优化的BP神经网络预测模型，并比较了三者优劣。接着，选取训练样本数据922组，验证样本数据10组，发现遗传算法优化的BP神经网络预测模型和小波神经网络预测模型预测效果较好，BP神经网络预测模型较差。最后，本文建立了混沌时间序列预测模型，并对含硅量[Si]进行了混沌局部线性一步预测和第二步预测。

摘要

针对问题二，首先，本文选取了**922组数据作为训练样本，10组数据作为验证样本**，将传统的BP神经网络预测模型、小波神经网络模型预测模型、基于遗传算法优化BP神经网络预测模型和混沌时间序列预测模型，分别预测后10炉次含硅量[Si]的结果与实际值进行对比，**计算得到：BP预测成功率为20%，小波预测为70%，GA+BP预测为60%，混沌预测为80%**。其次，通过不同的模型分别预测了后10炉次含硅量[Si]的结果，预测了炉温升降方向，**计算得到：BP预测成功率为40%，小波预测为100%，GA+BP预测为100%，混沌预测为100%**。最后，通过讨论神经网络训练函数的选取、神经网络性能参数的设定与混沌时间序列预测邻域半径的选取，分析了动态预测控制的可行性。

摘要

针对问题三，首先，本文根据遗传算法（GA）优化BP神经网络的预测模型，预测了含硫量[S]，并找出了含硫量[S]与含硅量[Si]、鼓风量FL和喷煤量PML之间的关系。然后，本文使用粒子群算法（PSO）优化了含硫量[S]，得出当鼓风量归一化后 $FL=0.7012$ 和喷煤量 $PML=0.0809$ 时，含硫量[S]有最小值。最后，本文分析了在含硫量[S]最优条件下，预测控制含硅量[Si]的预期效果，在含硫量[S]取最小值时，预测到此时含硅量[Si]较小，为 0.5712 。

针对问题四，我们结合建模背景、求解模型所得结果与分析结果所得结论，根据复杂流程工业智能控制的意义，浅谈了建模的心得体会。通过大数据挖掘，我们可以确定生产过程的最佳途径与最佳参数范围，获得最佳生产效果。

关键词：BP神经网络，小波神经网络，遗传算法，混沌时间序列，粒子群算法

十一. 模型的优缺点

11.1 优点

- BP神经网络预测模型在处理非线性，强耦合的海量数据时，采用基于改进的欧几里得距离相似性度量方法，很好地处理大量数据间的非线性和强耦合问题，为实际操作模式提供了充实的理论依据^[15]。
- 基于遗传算法优化BP神经网络的多元时间序列模型，其预测结果考虑了变量的时滞，因此预测结果误差较小。
- 混沌局部线性预测模型能很好地预测高炉铁水含硅量但就相关研究表明，对于国内中小型高炉的其它预测模型很难启及它的命中效果，对实际生产具有深远的指导意义。
- 同时，混沌时间序列预测方法用于高炉[Si]预测有很好的发展方向。

十一. 模型的优缺点

11.2 缺点

- 混沌局部线性预测模型在选取领域半径 ε 时具有很大的主观性，领域内的所有点均用于迭代规律的拟合，只考虑单一[Si]序列的历史数据预测[Si]等^[16]。
- 尽管高炉喷煤模式匹配和演化策略取得了理论上的成功，但研究深度广度还尚欠，且高炉喷煤冶炼过程操作模式优化方法目前仍处于探索阶段，还有待进一步完善。
- 虽然基于遗传算法优化的BP神经网络能提高网络的训练速度。但是，遗传算法复杂的操作过程，使网络的搜索时间随着所研究问题复杂度不同呈指数倍增长^[20]。
- 遗传算法在得到最优解时收敛缓慢也有可能收敛停止问题。



评委专家组点评

- 该论文数学建模与计算的思路层次清晰，计算结果数据完整，对不同类型模型与计算结果进行了比较。在比较中进行优化，说明数学应用于实际问题的基本功比较扎实。
- 所使用的数学模型包括BP神经网络模型，小波神经网络模型，遗传算法GA，混沌时间序列，交叉使用这些算法进行炉温[Si]的预测计算和比较。使用了粒子群算法进行[S]的优化。
- 论文的图表清晰，正确，没有错别字与变量错置等低级错误。
- 存在的缺陷是验证样本只使用了10炉数据进行验证，与大数据的要求有差距。
- 综合考虑作者的数学素质，论文的水平对比，推荐 A1053 为特等奖候选论文之一。

十二. 参考文献

- [1] 于卓颖, 郑涛. 基于神经网络的高炉铁水硅含量和硫含量预报模型[C]// 炼铁共性技术研讨会. 2015.
- [2] 史燕. 高炉炉温预测控制模型的研究[D]. 杭州电子科技大学, 2009.
- [3] 刘芳. 高炉炉温的多目标优化控制[D]. 浙江大学, 2001.
- [4] 郜传厚, 刘祥官. 高炉冶炼过程的混沌性辨识 I .饱和关联维数的确定[J]. 金属学报, 2004, 40(4):347-350.
- [5] 郜传厚, 周志敏. 高炉铁水Si含量的修正混沌加权一阶局部预报[J]. 物理学报, 2004, 53(12):4092-4097.
- [6] 郜传厚, 周志敏, 邵之江. 高炉铁水含硅量的混沌局部线性预测[J]. 金属学报, 2005, 41(4):433-436.
- [7] 郜传厚, 周志敏, 邵之江. 高炉冶炼过程的混沌性解析[J]. 物理学报, 2005, 54(4):1490-1494.
- [8] 郜传厚, 刘祥官, 周志敏. 基于Lyapunov指数的高炉铁水[Si]预报[J]. 高校应用数学学报:, 2006, 21(3):264-270.
- [9] 曾燕飞, 李虎山. 高炉铁水[Si]含量预测控制模型的设计与实现[J]. 微计算机信息, 2007, 23(10):64-66.
- [10] 贺诗波, 刘祥官, 郜传厚,等. 高炉硅含量预测控制的时间序列混合建模[J]. 浙江大学学报工学版, 2007, 41(10):1739-1742.

十二. 参考文献

- [11] 冯婷, 刘祥官, 马祥, 等. 高炉炉温预测控制的变系数回归模型[J]. 浙江大学学报工学版, 2007, 41(10):1743-1745.
- [12] 郜传厚, 渐令, 陈积明, 等. 复杂高炉炼铁过程的数据驱动建模及预测算法[C]// 第33期双清论坛. 2008:725-730.
- [13] 冯婷. 基于非参数回归的高炉炉温预测控制研究[D]. 浙江大学理学院 浙江大学, 2008.
- [14] 贺诗波. 自组织数据挖掘在高炉炉温预测控制中的应用[D]. 浙江大学理学院 浙江大学, 2008.
- [15] 熊欣. 基于改进的粒子群BP神经网络的高炉热状态预报模型的研究[D]. 重庆大学, 2008.
- [16] 高小强, 郑忠. 高炉铁水含硅量和含硫量动力学预报研究[J]. 钢铁, 1995(4):10-13.
- [17] 王宇红, 赵旭, WANGYu-hong, 等. 基于MLD模型的预测控制可行性与约束优先级研究[J]. 控制与决策, 2010, 25(9):1389-1392.
- [18] 李静. 基于数据挖掘的高炉铁水温度建模与预报[D]. 内蒙古科技大学, 2013.
- [19] 刘均会, 徐广尧. 用Si—S图分析高炉操作[J]. 包钢科技, 1981(1):45-49.
- [20] 李国勇. 智能控制及其MATLAB实现[M]. 电子工业出版社, 2005.

■

十三. 附录

附录一：预处理后的时间序列数据

炉次	含硅量 [Si]	含硫量 [S]	喷煤量 PML	鼓风量 FL	炉次	含硅量 [Si]	含硫量 [S]	喷煤量 PML	鼓风量 FL
1	0.2571	0.1944	0.6837	0.7622	484	0.2381	0.2500	0.7907	0.9586
2	0.2762	0.0556	0.6542	0.7703	485	0.2667	0.1389	0.7469	0.8673
3	0.2000	0.0556	0.5802	0.8179	486	0.2571	0.1944	0.4869	0.4198
4	0.1905	0.0833	0.6786	0.8216	487	0.2667	0.1806	0.5074	0.5470
5	0.2571	0.0556	0.7281	0.8417	488	0.2762	0.1667	0.5910	0.4170
6	0.3714	0.1250	0.6763	0.8487	489	0.1810	0.0833	0.4027	0.4188
7	0.2000	0.2361	0.8140	0.8078	490	0.1619	0.0556	0.7127	0.6866
8	0.1810	0.1806	0.7810	0.8062	491	0.1810	0.2361	0.4397	0.7916
9	0.2476	0.1389	0.8168	0.7972	492	0.1905	0.1389	0.3561	0.7911
10	0.1810	0.0556	0.7088	0.7831	493	0.1048	0.0556	0.1667	0.8473

..... 注：其余数据见论文原文中的附录。



致谢

- 感谢 团队中队友的团结协作；
- 感谢 中国优选法统筹法与经济数学研究会；
- 感谢 MathorCup 数学建模组委会；
- 感谢 评委老师的辛勤评阅；
- 感谢 全体工作人员的辛勤付出！



请各位老师批评指正！ 谢谢！

论文题目：基于改进的神经网络和混沌时间序列预测控制高炉炼铁过程

参赛队伍：A1053

参赛团队：张阳阳、王懿泽、李琅

指导老师：重庆大学 肖剑



重庆大学
CHONGQING UNIVERSITY

